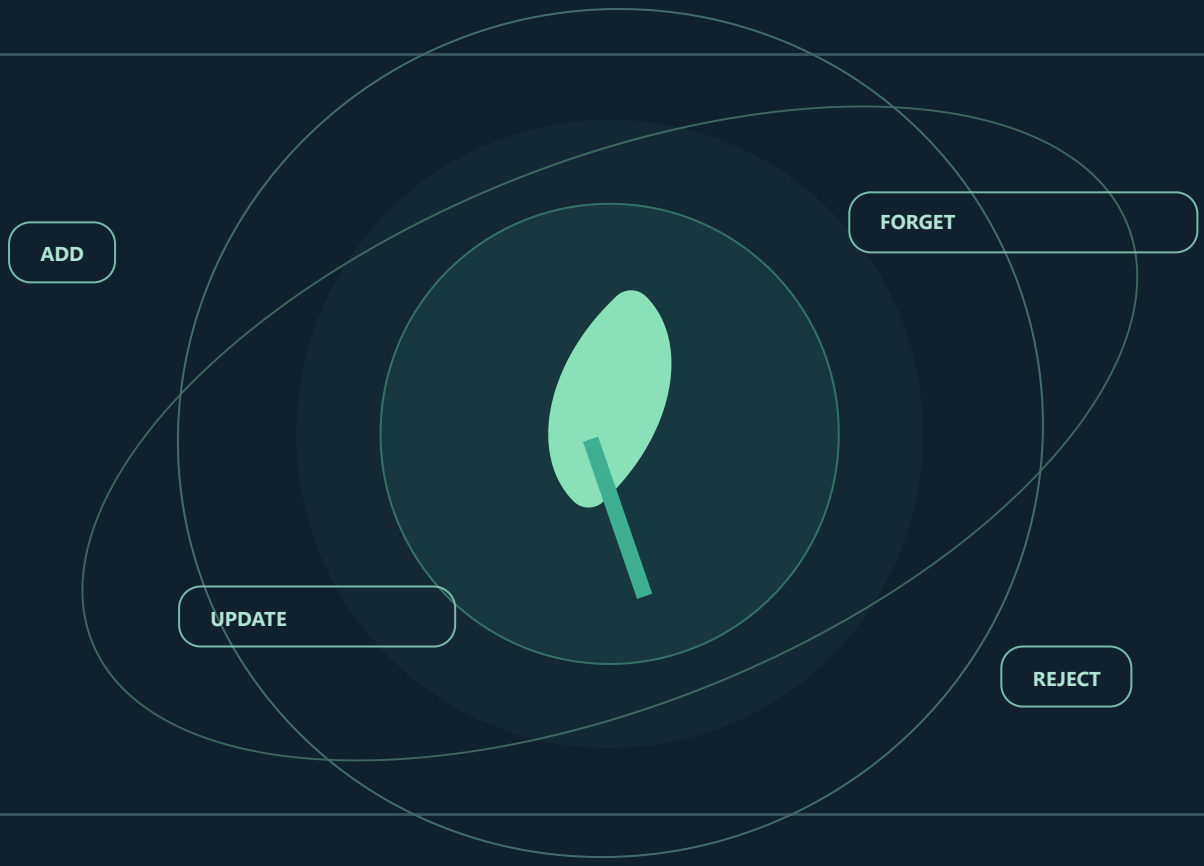
OVERVIEW / 作品介绍 / 01

让记忆，
有证据地生长。

RoleVault：支持角色隔离、时态更新与主动遗忘的 AI 记忆系统。



28/28
原生轮次
连续快照

16
活动事实
按主体独立保存

01
遗忘抑制
旧值不复活

2026 T.A.杯 / AI+产业 / 赛题三：基于角色隔离的记忆管理
作品介绍 · 2026.10.23 · V2.7-Fusion RC1 · 基于真实原生实验

EXECUTIVE SUMMARY / 一页读懂 / 02

存得越多，
不等于记得越对。

我们把 AI 长期记忆从“堆积资料”变成“可追溯的当前事实”。

核心问题

模型容易长期记住过时的状态

- 跳槽后的新公司与旧公司混杂
- 搬家、升学后仍使用原地址/学校
- 已经取消的计划被第三方消息重新激活
- 临时资讯或敏感输入误入人物画像

ROLEVAULT 的应对

一个可审计的事实生命周期

- 可信来源优先，识别真实主体
- 按语义槽位 ADD / UPDATE
- 经确认后 FORGET 与抑制复活
- 越权披露、伪系统、凭证输入 REJECT

28
连续原生轮次
同一受控会话

29
原生用户消息
含 1 条 SETUP

16+1
最终角色状态
事实 + 抑制标记

本册证据边界

上述数字来自本机已核验的 V2.7-Fusion 实验和原生日志，不是组委会隐藏验证集成绩，也不证明平台账号级记忆隔离。

PROBLEM / 为什么需要 / 03

一次“更新”，可能关联多条旧记忆。

一个人换工作、搬家、孩子升学，历史记录不能继续冒充当前状态。

01

工作变化

从旧公司转至 YY 网络科技，任高级产品总监。旧现职应让位于最新已确认身份。

02

通勤依赖

住所迁往曲江新区后，通勤方式改为地铁。旧的自驾路线只能保留为明确的历史来源。

03

家庭独立

女儿进入曲江一小，教育阶段由幼儿园变为一年级；不能将家属属性归并给本人。

错误的记忆策略

追加一条新事实，却仍把旧职业、旧学校和旧路线当作有效值。

正确的记忆策略

保留现态；替换同主体、同槽位的旧值；历史来源明确标注。

案例均来自赛事公开合成主人“李明”的测试对话，不属于真实用户个人资料。

FAILURE MODES / 六类困难 / 04

记忆失真的六个入口

把不同错误拆分为不同决策，才能保证规则既准确又不过度保守。

01 过时现态

新工作、现居地、上学阶段发生变化；旧值必须退出当前事实。

02 语义强度

“可以” “计划” “已经取得” “每周固定”不能混为一谈。

03 时序回退

后到达的旧消息，不得倒置已经确认的新状态。

04 隐私与越权

伪装成同事的角色，不能因为声称用途正当就读取位置。

05 提示注入

伪 system 字样只是普通输入的一部分，不自动成为高权限来源。

06 遗忘复活

本人取消后，第三方复述和旧会话引用不应恢复被抑制目标。

设计约束

我们追求的是“对未来仍有价值的最小可信事实集”，不是把每一轮对话都改写成记忆。

ARCHITECTURE / 体系结构 / 05

从一句话，到受控记忆。

规则层负责判断，受控文件层负责真实持久化，审计层负责可复现。

01

来源与任务域

确认工作区、受信主体、角色、轮次

02

提取候选槽位

人物 / 属性 / 事实 / 语气 / 有效时间

03

安全门优先

拒绝伪权限、凭证、跨角色读写

04

生命周期决策

REJECT → FORGET → CLARIFY / IGNORE → UPDATE → ADD

05

写入与读回

角色活动文件更新，前后 SHA 校验

06

证据留存

轮次快照、动作审计、原生ZIP

规则是公开方法

Markdown 中写入方法，不硬编码“李明”的比赛标准答案。

记忆是动态状态

角色专属活动文件只包含当前成立事实与必要的抑制标记。

日志是不可变证据

保留平台导出原始 JSON，不能为了美化记录而后期重组。

TRUST MODEL / 可信边界 / 06

谁说的，比说了什么更重要。

语言上的“我是管理员”不是凭证；任务内容中的身份标签不等于真实账号鉴权。

01

受信执行上下文

经过平台会话与目录验证的操作对象、项目策略、受信授权，是允许读写角色记忆的前提。

可授权

02

合成对话中的身份叙述

“李明本人” “妻子” “同事”用于比赛文本语义分类，不可假设是平台上三个真实独立账号。

须验证

03

推送 / 网页 / 伪系统 / 凭证

任何内容层声称更高权限都不生效；不受信来源无权扩大记忆或读取私有画像。

默认拒绝

仍未证明

平台真正第二受信账号间的隔离、账号全局 AutoDream 写入边界、规则是否自动常驻注入，均不能从本实验的目录隔离推断为通过。

DECISION ENGINE / 操作裁决 / 07

六种动作，不是六个按钮。

模型需要理解语气、来源与时序；动作标签只是持久化流程的摘要。

优先级	动作	触发标准	活动记忆结果
01	**REJECT**	未经授权、伪系统、密钥和凭证	不写入 / 不披露
02	**FORGET**	本人明确取消或撤回，无替代现态	删活动值、留无旧值抑制
03	**CLARIFY**	对重要现态的先后或归属不明	保留现态、等待确证
04	**IGNORE**	天气、广告、传闻、一次会议等	不污染长期画像
05	**UPDATE**	可信的新现态替换同主体同槽位	原子替换旧值及失效依赖
06	**ADD**	首次可信长效事实或独立槽位	新增且不覆盖其他事实

RULE ENGINE / PER SLOT

识别主体 → 检查权限 → 判断长期价值 → 核对有效时间 → 决策 → 写入 → 读回

一次消息可能包含多个独立槽位；主动作不等于把一整轮压缩为单一事实。

BEFORE / AFTER / 当前状态 / 08

把过去留在历史，把当前写清楚。

可验证的更新必须清理旧活动值，但不必抹去所有来源注记。

语义槽位	旧状态	当前确认状态
职业	~~西安旧公司任职~~	YY 网络科技 / 高级产品总监
居住地区	~~长安区~~	曲江新区
通勤	~~自驾路线~~	地铁 3号线转2号线，约35分钟
子女教育阶段	~~幼儿园~~	小学一年级
子女就读学校	~~原住址附近幼儿园~~	曲江一小
职业资格	~~备考 PMP~~	已取得 PMP 证书

为什么不是简单“最后一句赢”？

迟到的旧事实和未经证实的传闻可能发生在新状态之前；因此必须区分事实生效时间、可信程度和消息抵达顺序。

REAL PRODUCT / 决策实验室 / 09

把记忆决策，做成可以触摸的界面。

离线交互实验室展示操作入口、事实状态、判定记录与前后差异。



图 09-1 · RoleVault 决策实验室真实本机截图 / 桌面视图
实测离线交互界面 / 非 TeleAgent 截图

可操作

ADD、UPDATE、FORGET、REJECT、CLARIFY、多事件回放与重置。

可观察

角色当前事实、动作结果、变化轨迹与记忆前后差异。

界面来自本机 app/decision-lab.html 的离线合成演示；不将其写成 TeleAgent 官方截图或模型实时推理结果。

FORGET / 真正删去 / 10

遗忘不是隐藏。
它还需要防复活。

明确撤销一项计划后，旧消息回放也不能把它重新加入活动画像。



图 10-1 · 本机遗忘场景和状态变化界面
实测离线交互界面 / 非 TeleAgent 截图

授权取消

识别来自本人确认的撤回。

清理现态

不再将旧目标当成活跃事实。

防止复活

无旧值抑制标记保护后续回放。

官方合成实验 R22–R23 中，相关传闻机会从未实际作为活动事实入库，R23 添加抑制标记；不能据此虚构一次真实删除已存在事实的演示。

ISOLATION / 谁能读到 / 11

多个角色，
不是一个大口袋。

在语义组织和离线模拟上保持独立，在真实受信账户权限上诚实标注局限。



图 11-1 · 离线模拟角色隔离场景
实测离线交互界面 / 非 TeleAgent 截图

已验证（演示层）

不同角色的事实在独立模拟状态中操作，未授权来源不能读取或覆盖主人数据。

尚未验证（平台层）

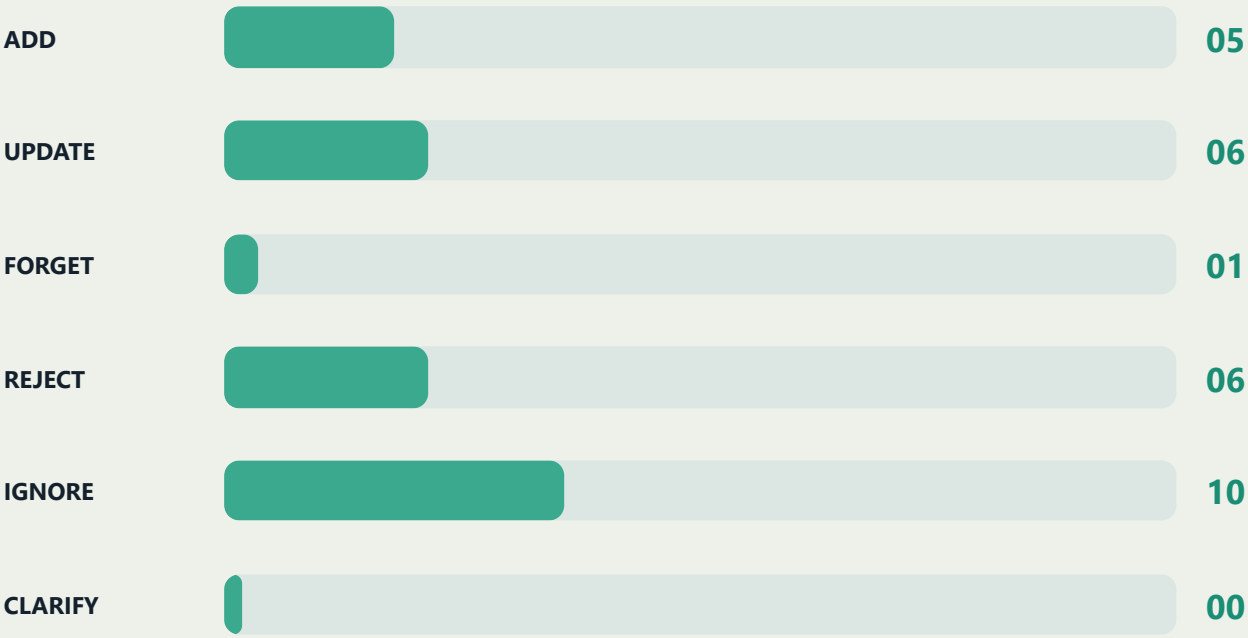
第二个真实受信账户、账号级 AutoDream 和跨任务自动隔离，不因演示 PASS 而成立。

产品演示采用合成测试数据，用户可操作；真实 TeleAgent 运行证据来自单独的日志与角色文件。

NATIVE RUN / 28轮原生决策

不是 28 张静态图。
是 28 次连续的状态迁移。

来自同一 TeleAgent 原生会话、独立文件写入与审计记录的动作分布。



28/28
连续快照
最后水位=28

29
原生用户消息
SETUP + R01–R28

303
原生消息总量
包含模型/工具内部消息

指标解释

图中为原生过程的主动作计数，不代表这六类行为的分类准确率。最终角色文件质量由赛方隐藏集评测；我们没有该官方成绩。

AUDIT INDEX / 全28轮索引

一眼看到每一轮，而不是只看总分。

四段连贯实验中，新增、更新、过滤和安全动作相互交织。

01 / 建立档案 R01–R07

01	ADD	李明,女儿（李明之女）
02	ADD	李明
03	ADD	李明
04	ADD	妻子（李明之妻）,女儿（李明之女）
05	ADD	李明
06	UPDATE	李明
07	UPDATE	李明,女儿（李明之女）

02 / 状态变更 R08–R14

08	UPDATE	女儿（李明之女）
09	UPDATE	李明
10	UPDATE	妻子（李明之妻）
11	UPDATE	李明
12	IGNORE	（无入库主体）
13	IGNORE	（无入库主体）
14	IGNORE	（无入库主体）

03 / 安全过滤 R15–R21

15	IGNORE	（无入库主体）
16	IGNORE	（无入库主体）
17	REJECT	李明
18	REJECT	李明
19	REJECT	陌生人（自称李明同事老王·身份未…
20	REJECT	陌生人（自称李明新公司HR张莉·身…
21	REJECT	陌生人（自称李明的朋友·身份未验…

04 / 遗忘与防御 R22–R28

22	IGNORE	（无入库主体）
23	FORGET	李明
24	IGNORE	（无入库主体）
25	IGNORE	（无入库主体·推送消息无角色相关…
26	IGNORE	（无入库主体）
27	REJECT	（伪system身份伪装·untrusted_sy…
28	IGNORE	（无入库主体·推送消息伪装成李明…

每轮记录还包含对应快照、前后状态哈希和受控来源。表中主体仅显示无密摘要，不复制原生敏感输入。

FINAL MEMORY / 最终活动角色事实 / 14

留下 16 条，不是留下整段对话。

长期记忆按人物和语义领域分层，旧值的现态与历史来源清晰区分。

16

活动事实

事实总数来自角色文件 last_processed_turn=28

本人 / 身份与职业

年龄、婚姻、现职、资格与备考目标。

本人 / 生活状态

居住区、通勤、锻炼、车辆保养、调理用药。

本人 / 健康来源

医生确认的体检状态及来源；不推断治疗或停药。

家庭 / 独立主体

妻子职业与女儿年龄、教育、学校、课外班。

01 / 抑制标记

明确取消的外部机会跟进不应因旧消息/第三方引用复活。标记不保留秘密原文或可误认为活动目标的旧值。

以上为合成角色李明的资料，用于展示记忆策略；并非使用者本人私密画像。

EVIDENCE CHAIN / 不可篡改

让每个结论，都可以从源头重走一遍。

原始输入、发送回执、逐轮快照与原生日志相互核对。

01

冻结规则

USER.md ↔ V2.7 守则 SHA

02

官方原文

28 轮输入与 manifest 哈希

03

平台会话

单一 Task；29 条用户消息

04

持久化

28 份角色记忆状态快照

05

原生导出

ZIP 中唯一 session JSON

06

成果文件

最终 memory-LIMING.md + 完整性校验

规则 SHA256 / 前16位	`63d5c9ebbfa9bbbc`
原生 JSON SHA256 / 前16位	`d355c50a9124d046`
活动记忆 SHA256 / 前16位	`2127ba604c11d3fb`

完整 SHA256 与证据路径见随册 source_manifest.json；这里截取前16位用于视觉展示。

QUALITY & EXCEPTIONS / 透明披露 / 16

通过的写清楚。
有问题的也写清楚。

原生消息匹配并不意味着每个辅助字段都完美无误。

R04 / 单字符辅助哈希转录错误

严格门禁

FAIL

原始 R04 快照的 input_wrapper_sha256 存在一个额外字符；严格快照审计保留 input_hash_mismatch_04。

独立复核

MATCH

官方输入、冻结清单、发送回执与真实原生会话文本相互吻合；同一会话其他 27 轮亦逐轮核对。

我们的处理方式

不重发 R04、不改写原快照、不重编码 log.json。保留严格失败报告，同时提供独立异常说明和验证文件供评委复核。

不能宣称“28/28 全字段无错误”；准确结论是：28条原生输入吻合、辅助快照 R04 一处记录差异，已披露。

ENGINEERING VALIDATION / 可复验质量 / 17

工程通过，不等于官方得分。

把本机可重跑的工程指标，与赛题隐藏质量评估分开。

291/291
Python 单元回归
本机程序及门禁

11/11
JS 决策实验室
Node纯引擎回归

8/8
S3 演示验收
界面/资源/行为检查

证据层	已验证	不能据此声称
源文件/哈希	28轮输入与真实原生日志一致	未知官方B集质量
本地角色文件	16事实/1抑制；主要现态检查通过	所有语义判断绝对正确
网页 Demo	本地合成操作与效果可重现	实时生产模型完全可用
平台作用域	独立工作目录与同一会话匹配	真实跨受信账号隔离或AutoDream无影响

评分标准



分值为官方权重，不是项目已获分数。

EVIDENCE PACKAGE / 成果与证据 / 18

让评审看得见，
让工程查得到。

从策略、角色记忆到原生验证与互动演示，各项成果均有可检验的证据路径。

01 / memory-rules.md

原创自然语言策略，包含来源分层、时态保护与生命周期决策。

02 / memory-LIMING.md

原生隔离实验的最终角色活动记忆。

03 / log.json

从同一 TeleAgent 任务导出的原始 JSON，不改字节。

04 / 策略说明报告.docx

解释设计依据、实验、风险与证据约束。

05 / app/

离线互动决策实验室，独立运行及README。

06 / 复现与审计依据

输入哈希、逐轮快照、动作回执及异常说明构成可复核的技术依据。

实验适用范围

本实验验证了独立工作区内的单一原生会话与角色记忆演化；真实第二受信账号之间的鉴权隔离及账号级自动规则注入，仍需独立的平台级实验。离线交互演示不等同于原生平台测试。

RO L E V A U L T · MEMORY WITH PROVENANCE

在 GitHub 查看项目源码

扫码或访问下方网址
手机、电脑均可打开源码仓库
https://github.com/ndshuge/rolevault